

Android in the Wild

没看

AndroidWorld

对于每一个任务都有自己的奖励机制, 状态控制

奖励机制使用 **adb** 来获取系统状态; 对于隐式系统状态采用检查 UI element 的方式判断是否完成

SPA-BENCH

related works

Agents

三种:

- 1. 基于文本: 使用 UI 的 XML 文件, 或将图片转换成文本描述
- 2. 基于图像: 使用截图
- 3. 两者结合

Evaluations

分为人工和自动

自动的分为三类:

- 1. 基于动作: 与人类的演示动作比较, 但一般成功的动作轨迹不止一条
- 2. 基于状态: 检查最终的状态是否最优, 但是次优的动作可能被忽略
- 3. 两者结合

对比 AndroidWorld

Benchmark	Third-party app?	Cross-app?	Chinese app?	Difficulty level?	Number of tasks	Number of agents	Number of metrics	Free of hand-crafted validation?	Information for success detection
AndroidArena (Xing et al., 2024)	✗	✓	✗	✗	221	1	4	✗	Action only
AndroidWorld (Rawles et al., 2024a)	✓	✓	✗	✓	116	3	1	✗	State only
LlamaTouch (Zhang et al., 2024)	✓	✗	✗	✓	495	4	1	✗	State only
B-MoCA (Lee et al., 2024)	✗	✗	✗	✗	60	3	1	✗	State only
MobileAgentBench (Wang et al., 2024c)	✗	✗	✗	✓	100	5	6	✗	Action and State
SPA-BENCH	✓	✓	✓	✓	340	11	7	✓	Action and State

AndroidWorld 的问题:


不支持中文; 需要手工的 validation; 判断任务完成只依赖系统状态;

SPA-BENCH

Task construction

包含一个简明的任务描述, 一组人类操作轨迹的截图, 和最终状态的核心组件

Agent Framework



每一轮选一个任务和 Agent, 返回 Agent 的动作轨迹

同时, 模拟器将系统状态保存在快照中, 减少任务 setup 的时间


Automated Evaluation Framework

有 7 个评判准则

同时, 正确性检测分为 Single-App 和 Cross-App

1. Single-App


使用两个 MLLM, 先粗略地根据 key component 检测, 筛选掉不相关的轨迹; 然后再用另一个 MLLM 根据任务描述和轨迹综合判断是否成功



2. Cross-App

先用一个 MLLM 将任务分成多个子任务, 另一个 MLLM 将轨迹分为对应的阶段

然后每一阶段依次用上面的方法判断



参考

1. [Android in the Wild: A Large-Scale Dataset for Android Device Control](#)
2. [ANDROIDWORLD: A DYNAMIC BENCHMARKING ENVIRONMENT FOR AUTONOMOUS AGENTS](#)
3. [SPA-BENCH: A COMPREHENSIVE BENCHMARK FOR SMARTPHONE AGENT EVALUATION](#)